

深度学习导论作业 4 - 基于SimCLR的AIGC生成图像检测

一、任务说明

自2022年底Stable Diffusion、Midjourney等AIGC技术爆发以来，区分"真实照片"与"AI生成图像"成为了计算机视觉领域极具挑战性的新课题。本作业要求使用[SimCLR](#)（建议在实验前阅读原文）框架，提升模型对真实/AI生成图像的分类能力。我们使用CIFAKE数据集，一个包含CIFAR-10的真实图像和由Stable Diffusion生成的伪造图像的数据集。**如果觉得在整个数据集上跑实验太慢，你可以按比例取其子集进行训练和测试，但不应该少于总数据量的10%。**

二、实验步骤

1. 数据增强

SimCLR的核心是构建正样本对。需要利用 `torchvision.transforms` 构建两个**随机**增强流，对同一张32x32图片应用随机增强，生成两个View。你可以使用包括但不限于以下的增强操作：裁剪，水平翻转，旋转，颜色抖动，转换为灰度图，高斯噪声等。

2. 模型构建

Encoder：使用轻量级卷积网络（如ResNet-18和MobileNet-v2）。注意需调整第一层卷积以适应32x32输入。

Projection Head：一个两层的MLP（Linear -> ReLU -> Linear），将Encoder提取的特征（如128维）映射到更低维的空间（如64维）计算Loss。

```

class SimCLRModel(nn.Module):
    def __init__(self, feature_dim=128, projection_dim=64):
        super().__init__()
        self.encoder = ... # CNN/ResNet/MobileNet ...
        self.projection_head = nn.Sequential(
            nn.Linear(feature_dim, feature_dim),
            # nn.BatchNorm1d(feature_dim),
            nn.ReLU(),
            nn.Linear(feature_dim, projection_dim)
        )

```

3. 损失函数

实现SimCLR的NT-Xent损失函数，不允许使用现成的对比学习库。

参考算法：在有 N 个样本的Batch中，设 z_i 和 z_j 为两个View的特征， $s_{i,j}$ 为它们的余弦相似度，则：

$$\ell_{i,j} = -\log \frac{\exp(s_{i,j}/\tau)}{\sum_{k=1}^{2N} \mathbf{1}_{i \neq k} \exp(s_{i,k}/\tau)}$$

$$\mathcal{L} = \frac{1}{2N} \sum_{k=1}^N (\ell_{2k-1,2k} + \ell_{2k,2k-1})$$

```

def info_nce_loss(z_i, z_j, temperature=0.5):
    # z_i: (Batch_size, Feature_dim)
    # z_j: (Batch_size, Feature_dim)
    # SimCLR Loss
    pass

```

4. 训练流程与下游任务评估

阶段 1 - 无监督预训练：丢弃标签，使用SimCLR框架训练Encoder + Projection Head。

阶段 2 - 冻结评估：冻结Encoder的权重。将Encoder接上一个全新的单层线性分类器，仅使用1%/10%的带标签数据（Real vs Fake），使用交叉熵损失训练此分类器。

Baseline：不使用自监督预训练，直接从头开始随机初始化一个Encoder，仅用这1%/10%的标签数据训练，对比两者的最终准确率。

三、附加实验（选做至少2个）

1. **比较不同Loss的训练效果**：将Loss替换为其他对比学习Loss（如Triplet Loss、Contrastive Loss），比较不同Loss对训练效果的影响。
2. **Projection Head结构分析**：设计不同结构的Projection Head（如加入BatchNorm、改变隐藏层维度），分析其对训练效果的影响。
3. **超参数分析**：分析实验中超参数的影响，如Loss中的温度系数，batch_size大小（影响自监督中的负样本数量）

四、报告要求

1. 以pdf形式提交，统一命名为 学号-组别（第一/二/三组）-姓名.pdf。建议使用LaTeX或Markdown完成报告的撰写，不推荐使用Word导出pdf。所提交的作业压缩包中应包含且仅包含： pdf报告 和 实验代码文件夹，无需提供展示结果的图片原件或源数据。**注意：提交的作业文件不要超过20MB。**
2. 报告内容须至少：
 - 简述实验所用的模型架构或算法
| 45%，含代码的完成分
 - 按要求汇报主要的实验结果
| 15%，不考察实验评价指标的高低
 - 展示附加实验的结果与结论
| 30%，含对应的代码实现
 - 简短地讨论、总结实验结果与结论
| 10%，简要总结概括即可，可加上自己的思考

其中，本次实验要求：

- 展示各种数据增强方法的效果
- 介绍Encoder的架构
- 汇报实验设置的细节，如训练测试集的大小，超参数和训练epoch数等
- 记录在不同Encoder架构和冻结评估比例（1%/10%）下的训练结果（Accuracy与F1 Score），并与baseline比较
- 完成附加实验

可能造成扣分的行为：没有文字说明；实验完全失败；图表极不美观；AIGC痕迹**过于**明显。

3. 尽管按质按量完成以上内容就可以拿满报告和代码分，但我们仍鼓励在报告中进行理论分析，拓展实验和更深层次的思考讨论，这些拓展内容都可以在非满分的情况下提供**附加分**。

参考文献

1. Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. 2020. A simple framework for contrastive learning of visual representations. In Proceedings of the 37th International Conference on Machine Learning (ICML'20), Vol. 119. [JMLR.org](https://jmlr.org), Article 149, 1597–1607.
2. Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. 2016. Deep residual learning for image recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 770–778.
3. Mark Sandler, Andrew Howard, Menglong Zhu, Andrey Zhmoginov, and Liang-Chieh Chen. 2018. MobileNetV2: Inverted residuals and linear bottlenecks. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 4510–4520.